

به نام خدا

**BSS**

Hw-1

محمد رضا آرانی

**810100511**

دانشگاه تهران

1401/12/08

## جدول محتویات

بخش 1-:	3
سوال 1-:	3
سوال 2-:	7
سوال 3-:	9
سوال 4,5-:	13
سوال 6-:	14
بخش 2-:	16
سوال 1-:	16
سوال 2-:	17
سوال 3-:	17
سوال 4-:	18
سوال 5-:	20
سوال 6-:	23
سوال 7-:	24
سوال 8-:	26
سوال 9-:	28

## بخش-1:

### سوال-1:

بخش اول

منبع  $s_1$  را که یک فرآیند تصادفی دارای توزیع یکنواخت بین  $[-3 \ 3]$  می باشد با  $T=1000$  نمونه و منبع  $s_2$  را که یک فرآیند تصادفی دارای توزیع یکنواخت بین  $[-2 \ 2]$  می باشد با  $T=1000$  نمونه تولید کنید. این دو منبع را به صورت خطی و آنی توسط ماتریس مخلوط کننده  $A = \begin{bmatrix} 0.6 & 0.8 \\ 0.8 & -0.6 \end{bmatrix}$  ترکیب کنید و مشاهدات  $x_1$  و  $x_2$  را تولید کنید.

(۱) نمودار پراکندگی  $x_2$  را بر حسب  $x_1$  رسم کنید (scatter plot). رابطه ی این شکل با ماتریس  $A$  چیست؟

در این سوال، پس از تولید نمونه‌ها، آنها را با ماتریس  $A$  مخلوط کرده و به ماتریس مشاهدات می‌رسیم.

در عمل داریم:

$$x_1(t) = A_{11}s_1(t) + A_{12}s_2(t);$$

$$x_2(t) = A_{21}s_1(t) + A_{22}s_2(t);$$

با در نظر گرفتن بردارهای مکانی  $a_1$  و  $a_2$  به صورت زیر:

$$a_1 = [A_{11}; A_{21}];$$

$$a_2 = [A_{12}; A_{22}];$$

مشاهدات ما به فرم زیر در خواهد آمد:

$$X_{2 \times T} = A_{2 \times 2} S_{2 \times T} = a_1 s_1(t) + a_2 s_2(t);$$

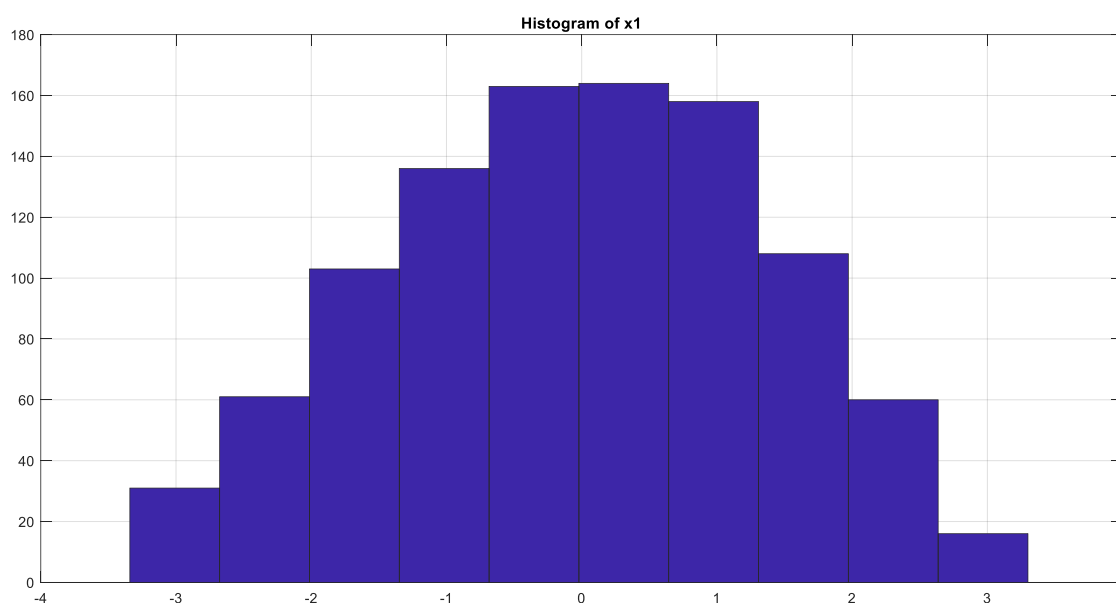
در واقع هردوی  $x_1$  و  $x_2$  حاصل ترکیب خطی از نمونه‌های یکنواخت اند که منجر به توزیعی شبیه به توزیع Irwin-Hall که درواقع جمع تعدادی فرآیند یکنواخت مستقل است، می‌شود.

در اینجا ضرایب وزن متفاوتی به هر منبع توسط ماتریس  $A$  که همان کانال ما بوده، نسبت داده می‌شود.


توزیع جدید باید از روی کانولوشن توزیع‌های وزن دار  $S_1$  و  $S_2$  به دست آید.

با توجه به اینکه توزیع  $S_1$  و  $S_2$  یکنواخت می‌باشد، توزیع هر یک از مشاهدات نیز باید تقریباً به صورت مثلی که همان کانولوشن دو پالس مربعی می‌باشد درآید.

در شکل زیر توزیع‌های  $x_1$  و  $x_2$  را خواهیم دید:

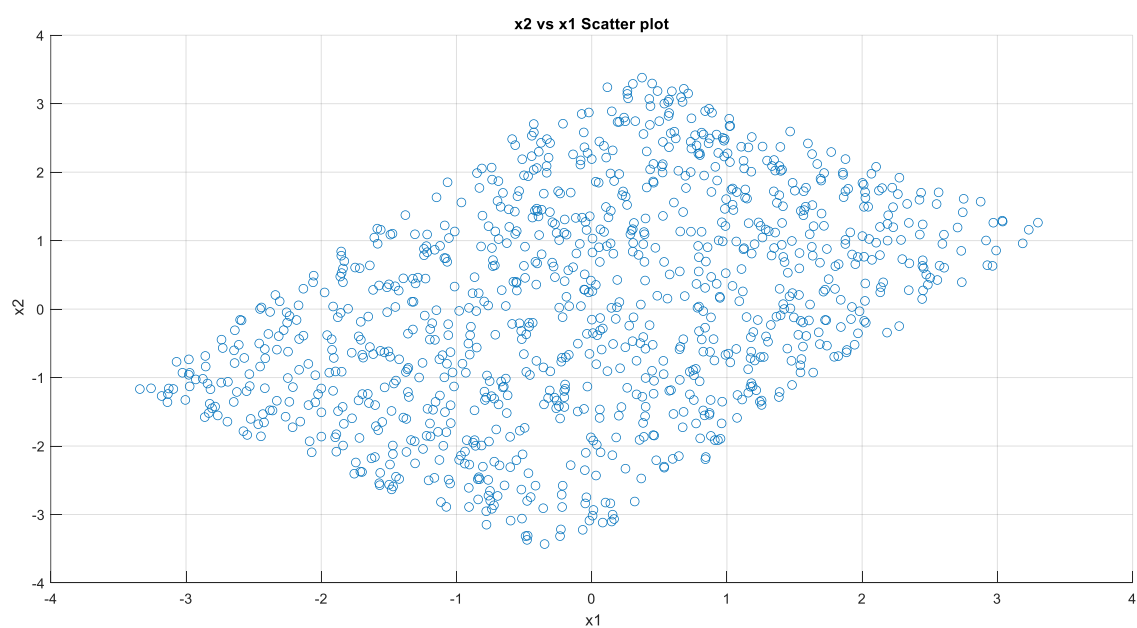


شکل 1



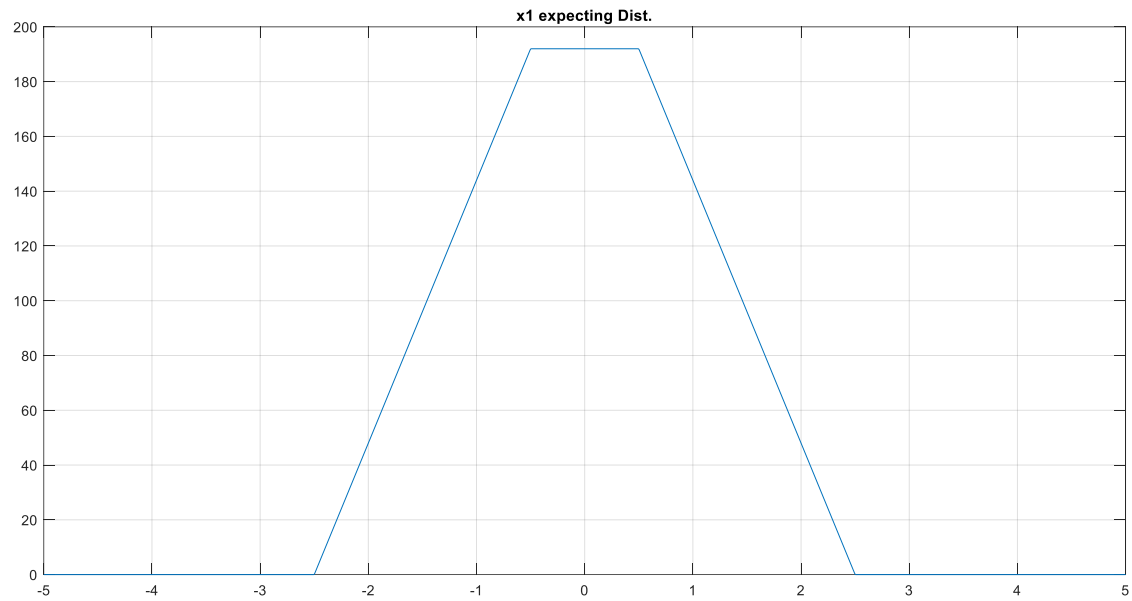
شکل 2

توزیع داده‌ها به صورت زیر خواهد بود:

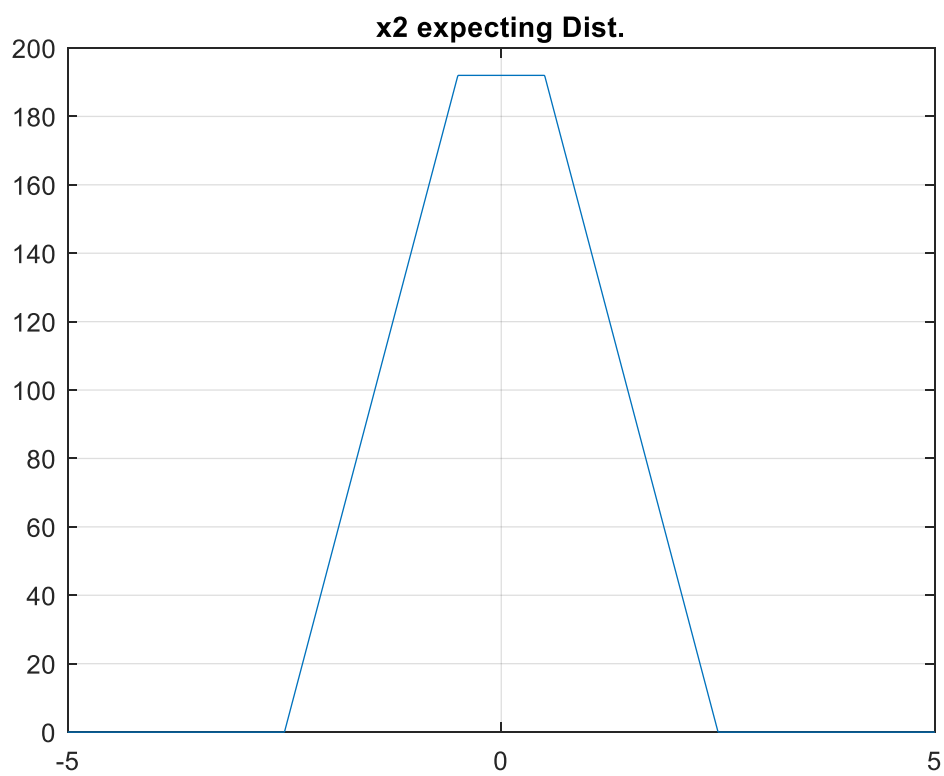


شکل 3

توزیع داده‌های مورد انتظار به صورت زیر است:



شکل 4




شکل 5

## سوال-2:

۲) یک روش ریاضی (مرتبط با پاسخ قسمت ۱) پیشنهاد دهید که به صورت اتوماتیک ماتریس  $A$  را در این مساله بیابیم. روش خود را پیاده سازی کنید.

برای پیدا کردن ماتریس  $A$  نیاز هست که بردارهای  $a_1$  و  $a_2$  را به درستی انتخاب کنیم. برای پیدا کردن درست این بردارها، بهترین کار استفاده از PCA بوده که بهترین محور را برای توزیع موجود جهت داشتن بیشترین تفکیک پذیری انتخاب می کند. حال از آنجا که فرض بر آن است که نه درس ML پاس کردیم و نه پردازش آرایه ای، می توان حاشیه های این داده ها پیدا کرده و آنها را به عنوان بردارهای متناسب انتخاب کنیم.

در اینجا می توان از شکل هندسی حاصله استفاده کرد و از روی جمع و تفریق دو محور مورد نظر، نقاط مورد علاقه را پیدا کرد و سپس از روی سیستم دو معادله دو مجهول،  $a_1, a_2$  را به دست آورد.



شکل 6


در شکل فوق، محور زرد،  $a_1$  و محور آبی  $a_2$  می باشد.

روش پیشنهادی برای پیدا کردن اتوماتیک  $a_1$  و  $a_2$ :

در شکل فوق، خط مشکی، نشان دهنده  $a_1 + a_2$  و خط سبز نشان دهنده  $a_1 - a_2$  می باشد.

$$Diff = a_1 - a_2;$$

$$sum = a_1 + a_2;$$



شکل 7

$$sum + Diff = 2 * a_1;$$

$$sum - Diff = 2 * a_2;$$




### سوال-3:

۳) حال به ماتریس مشاهدات نویز (با قدرت پایین) اضافه کنید و روش پیشنهادی در قسمت قبل را روی آن اعمال کنید. آیا روش شما در سناریوی جدید نیز قابل پیاده سازی است؟ اگر خیر، روشتان را تغییر دهید. عملکرد روشتان را در حضور نویز گزارش دهید. متری پیشنهاد دهید که نشان دهد روش شما در حضور نویز نیز عملکرد مناسبی دارد.


ابتدا نقاط ابتدا و انتها را مانند شکل قبل به دست آورده، سپس یک خط تشکیل می‌شود و ما نقاط نزدیک به این خط را شناسایی کرده و سپس آنها را در یک ست جمع آوری کرده و بر این ست جدید یک خط برازش خواهیم کرد. خط  $fit$  شده باید نسبت به داده‌های نویزی نیز خوب عمل کند.

در حضور نویز داده‌ها شکل زیر را به خود خواهند گرفت:



شکل 8


نویز گاوسی با واریانس 0.1



شکل 9

نویز گاوسی با واریانس 0.5

حال نقاط را مانند قبل انتخاب می‌کنیم:



شکل 10

مشاهده می‌شود که نقاط کمی با جای ایده‌آل خود فاصله دارند:

روش همچنان به درستی عمل می‌کند و مقادیر  $a_1$  ,  $a_2$  در هر دو حالت تقریباً یکسان اند.


```
>> a_2_ordinal_Noisy
a_2_ordinal_Noisy =
    -2.9930    2.2637
>> a_2_ordinal
a_2_ordinal =
    -2.9930    2.2637
```

شکل 11

```
>> a_1_ordinal_Noisy
a_1_ordinal_Noisy =
    3.6483    4.6947
>> a_1_ordinal
a_1_ordinal =
    3.6483    4.6947
```

شکل 12

پس از پیدا کردن خط، به خروجی زیر خواهیم رسید:



شکل 13

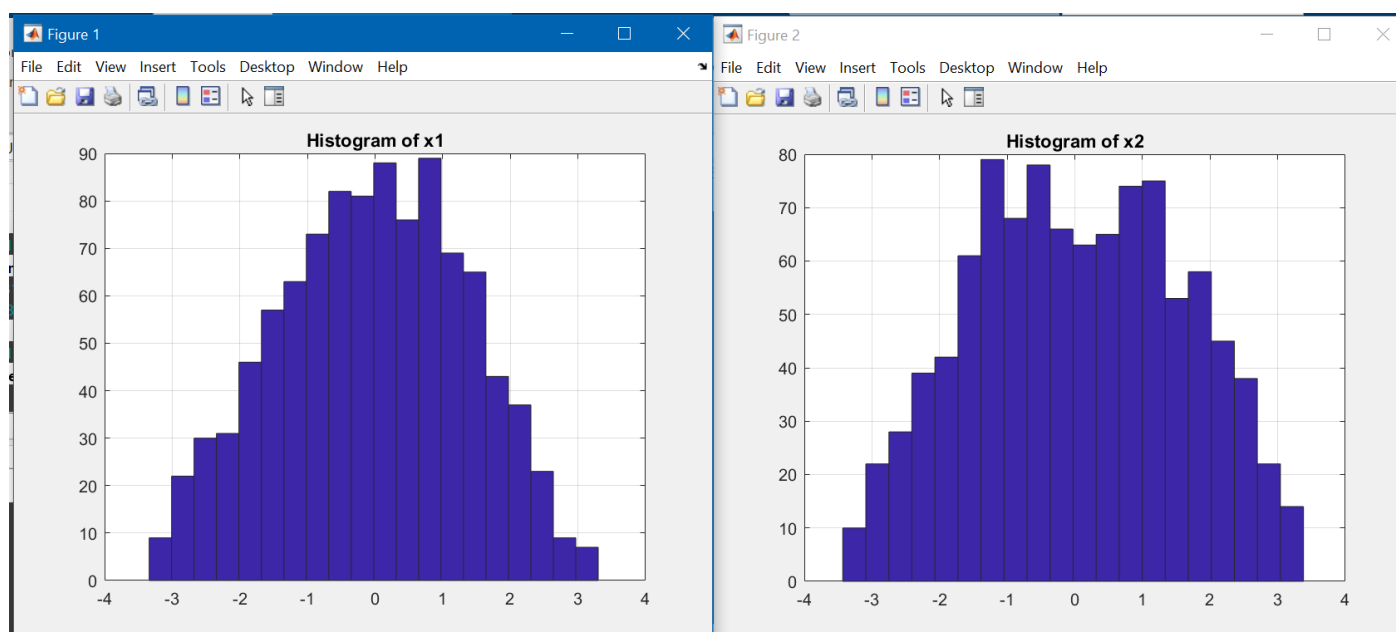
که تقریباً به درستی این خطوط شناسایی شده اند.

برای پیشنهاد دادن متری که نشان دهد روش ما در حضور نویز به درستی کار می کند، باید به این مسئله به صورت یک مسئله **classification** نگاه کرد که در آن اگر داده ها در سمت درستی از خط قرار گرفته بودن، آنها را درست لیبل بزند و اگر خیر لیبل غلط بزند و در نهایت تعداد درست را به تعداد کل تقسیم نموده و درصد دقت را به دست آورد.

۴) هیستوگرام  $x_1$  را با در نظر گرفتن 20 بین (bin) رسم کنید و با استفاده از روابط آماری و ریاضی تابع توزیع  $x_1$  را هم به دست آورید. تابع توزیعی که به دست آورید باید با هیستوگرام تطابق داشته باشد.

۵) قسمت ۴ را برای  $x_2$  تکرار کنید.

در قسمت‌های قبل توضیح داده شد.



شکل 14

در واقع هردوی  $x_1$  و  $x_2$  حاصل ترکیب خطی از نمونه‌های یکنواخت اند که منجر به توزیعی شبیه به توزیع Irwin-Hall که درواقع جمع تعدادی فرآیند یکنواخت مستقل است، می‌شود.

در اینجا ضرایب وزن متفاوتی به هر منبع توسط ماتریس  $A$  که همان کانال ما بوده، نسبت داده می‌شود.

توزیع جدید باید از روی کانولوشن توزیع‌های وزن دار  $S_1$  و  $S_2$  به دست آید.

با توجه به اینکه توزیع  $S_1$  و  $S_2$  یکنواخت می‌باشد، توزیع هر یک از مشاهدات نیز باید تقریباً به صورت مثلی که همان کانولوشن دو پالس مربعی می‌باشد درآید.

```

38 %
39
40 Ts=1;
41 fs=1/Ts;
42 fsample=100;
43
44 Tsample=1/fsample;
45 t=-5:Tsample:5; % time vector
46
47 TAU1 = 6 ;
48 TAU2 = 4 ;
49
50 h1=heaviside(t+TAU1/2)-heaviside(t-TAU1/2);
51 h2=heaviside(t+TAU2/2)-heaviside(t-TAU2/2);
52
53 New_Dist=conv(0.8*h1,-0.6*h2);
54 figure()
55 plot(linspace(-5,5,length(New_Dist)),abs(New_Dist));
56 grid on
57 title("x2 expecting Dist.")
58

```

شکل 15

## سوال-6:

۶) فرض کنید  $T$  به اندازه کافی بزرگ باشد و بعد از کشیدن هیستوگرام‌ها (قسمت‌های ۴ و ۵) شکل‌ها دقیقاً مطابق تابع توزیع‌هایی باشند که با استفاده از روابط آماری و ریاضی به دست می‌آید. همچنین فرض کنید توزیع دقیق منابع (یکنواخت بودنشان + بازه‌ی مقادیرشان) را هم می‌دانیم. آیا در این حالت با استفاده از هیستوگرام‌ها می‌توان مساله BSS را حل کرد؟ توضیح دهید.

با داشتن دانش نسبت به بازه و مقادیر از روی هیستوگرام، می‌توان به صورت زیر داشت:

$$s_1 \sim U(p, q)$$

$$s_2 \sim U(m, n)$$

$$x_1 = A_{11}s_1 + A_{12}s_2 \Rightarrow$$

$$x_1 \sim U(A_{11}p, A_{11}q) * U(A_{12}m, A_{12}n);$$

با داشتن 4 معادله و 2 مجهول، می‌توان با داشتن بازه‌ی داده‌ها، از روی هیستوگرام مقادیر  $A_{11}$  و  $A_{12}$  را پیدا کرد.

با ادامه‌ی همین فرآیند برای  $x_2$  می‌توان مقادیر  $A_{21}, A_{22}$  را پیدا کرد.

## بخش-2:


### سوال-1:

تابع هدف دو متغیره زیر را در نظر بگیرید

$$f(\underline{x}) = x_1^2 + x_2^2 - 4x_1 - 6x_2 + 13 + x_1x_2$$

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

(۱) با استفاده از دستور mesh این تابع را بر حسب  $x_1$  و  $x_2$  در بازه ی  $-10 < x_2, x_1 < 10$  به صورت سه بعدی رسم کنید. بهتر است تابع هدف را به صورت db رسم کنید تا تغییرات تابع هدف برایتان واضح تر شود.

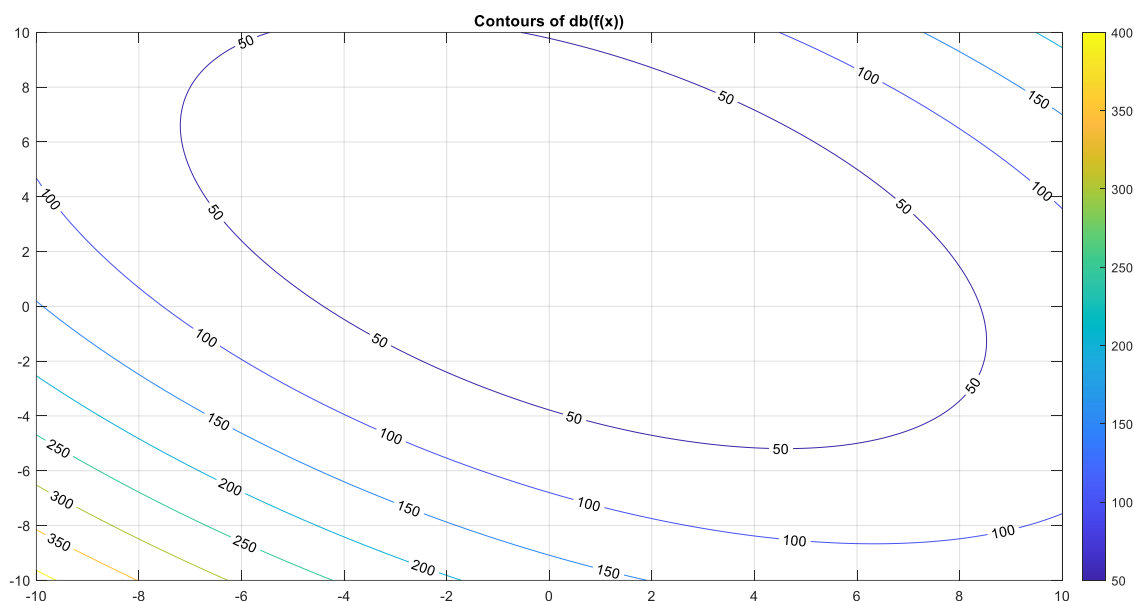


شکل 16



## سوال-2:

۲) با استفاده از دستور contour سطوح هم پتانسیل این تابع را در فضای دو بعدی رسم کنید. مقادیر سطوح هم پتانسیل نیز روی شکل نشان داده شود (help دستور را مطالعه کنید).



شکل 17

## سوال-3:

۳) بردار گرادیان (g) و ماتریس هسین (H) را محاسبه کنید. با توجه به ماتریس هسین به دست آمده، ثابت کنید تابع هدف داده شده convex است و در نتیجه فقط یک مینیمم دارد. (همان طور که در کلاس اشاره شد باید ثابت کنید نامساوی  $\underline{x}^T H \underline{x} > 0$  به ازای همه ی مقادیر برداری  $\underline{x}$  برقرار است).

برای محاسبه ی بردار گرادیان و هسین داریم:

$$gf = \begin{bmatrix} \frac{\partial}{\partial x_1} \\ \frac{\partial}{\partial x_2} \end{bmatrix} f = \begin{bmatrix} 2x_1 - 4 + x_2 \\ 2x_2 - 6 + x_1 \end{bmatrix}$$

$$Hf = \begin{bmatrix} \frac{\partial^2}{\partial x_1^2} & \frac{\partial^2}{\partial x_2 \partial x_1} \\ \frac{\partial^2}{\partial x_2 \partial x_1} & \frac{\partial^2}{\partial x_2^2} \end{bmatrix} f = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

برای اثبات اینکه این تابع convex است، باید ماتریس هسین آن، PD و یا PSD باشد.  
اگر تمامی مقادیر ویژه‌ی آن مثبت باشد، آنگاه این ماتریس PD است.

$[V,D] = \text{eig}(A)$  returns diagonal matrix D of eigenvalues and matrix V whose columns are the corresponding right eigenvectors, so that  $A*V = V*D$ .

```

24 %% Hessian
25
26 H = [2,1;1,2];
27 [V,D] = eig(H);
28 disp(D);
29
30

```

Command Window

```

1      0
0      3

```

شکل 18

در نتیجه این ماتریس PD است و تابع ما Convex می‌باشد.

#### سوال-4.

(۴) نقطه‌ای که مینیمم تابع در آن رخ می‌دهد را با صفر قرار دادن بردار گرادیان به دست آورید.

برای این کار داریم:

```

29
30 %% Solve g=0
31
32 A = [2,1;1,2];
33 B = [4;6];
34
35 Glob_Point = A\B;
36
37 %%

```

## Command Window

```

B = [4;6];

Glob_Point = A\B;
>> Glob_Point


Glob_Point =

    0.6667
    2.6667


```

شکل 19

و در نهایت داریم:



شکل 20




شکل 21

## سوال-5:

۵) از نقطه ی اولیه  $x_1 = x_2 = 6$  روش Steepest Descend را به ازای  $\mu$  های 0.01 و 0.1 پیاده کنید. آیا در هر دو حالت الگوریتم همگرا شد؟ کدام یک سریع تر همگرا شد؟ نمودار همگرایی (مقدار تابع هدف بر حسب شماره iteration) را به ازای هر دو  $\mu$  روی یک شکل رسم کنید.


$$\mathbf{x}_1 = \mathbf{x}_0 - t_0 \nabla f(\mathbf{x}_0)$$

شکل 22




شکل 23

برای نمودار همگرایی داریم:

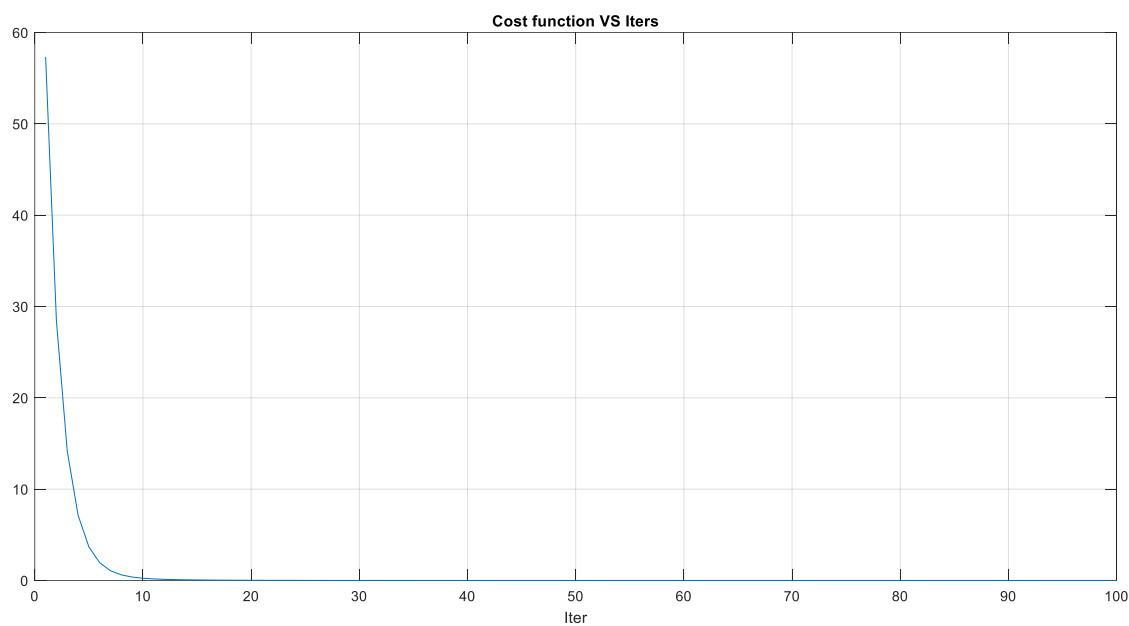


شکل 24

نمودار همگرایی برای  $\text{mio}=0.01$



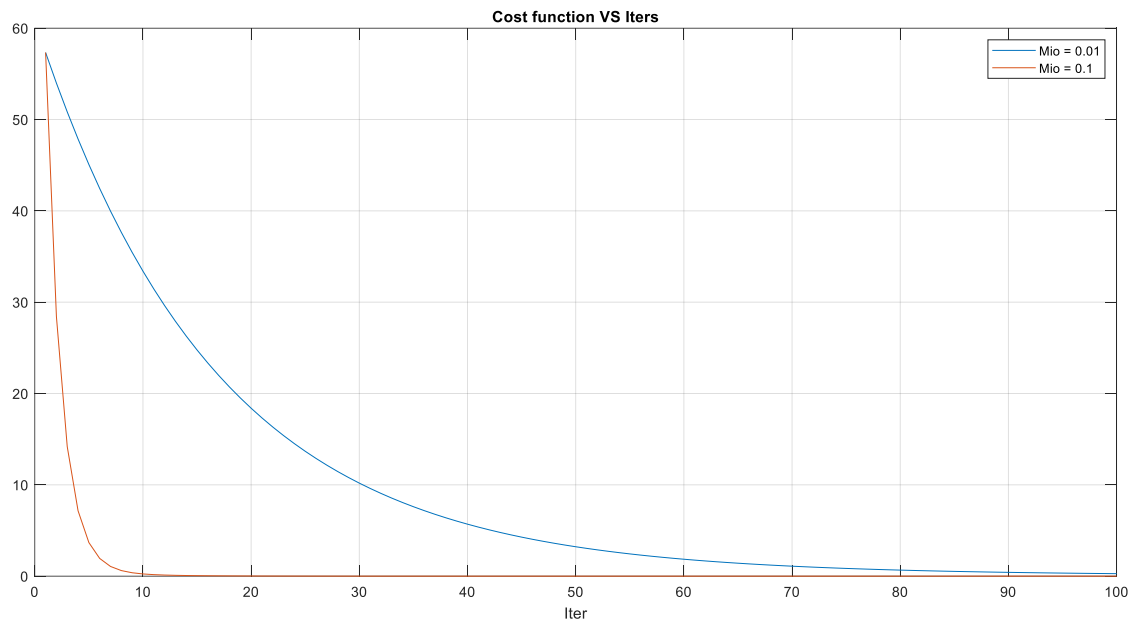
شکل 25



شکل 26


نمودار همگرایی برای  $\text{mio}=0.1$

واضح است که برای  $\text{mio}=0.1$  با طول قدم های بلندتر سریع تر همگرا می شویم.




## سوال-6.

۶) از نقطه ی اولیه  $x_1 = x_2 = 6$  روش Newton را پیاده کنید. در چند iteration الگوریتم همگرا می شود؟ دلیل این اتفاق را شرح دهید.



شکل 27



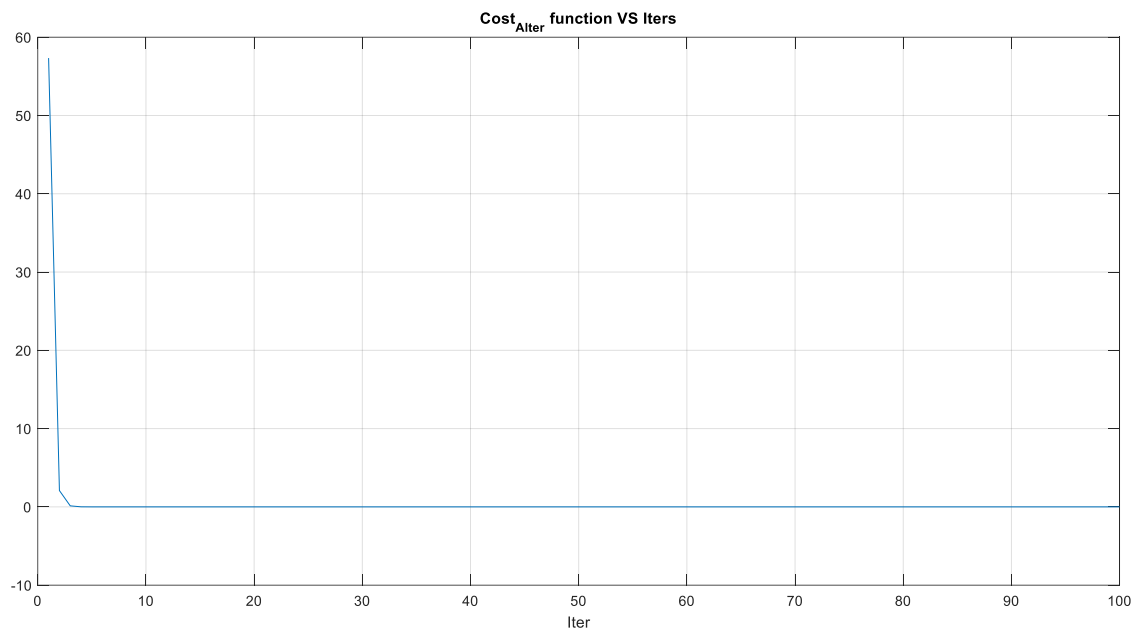
شکل 28

همانطور که مشاهده می‌شود، این روش به سرعت همگرا شده و از روش‌های قبلی سریعتر است چرا که بر اساس مشتق دوم و اطلاعات مرتبط با تحدب عمل می‌کند.

## سوال-7:

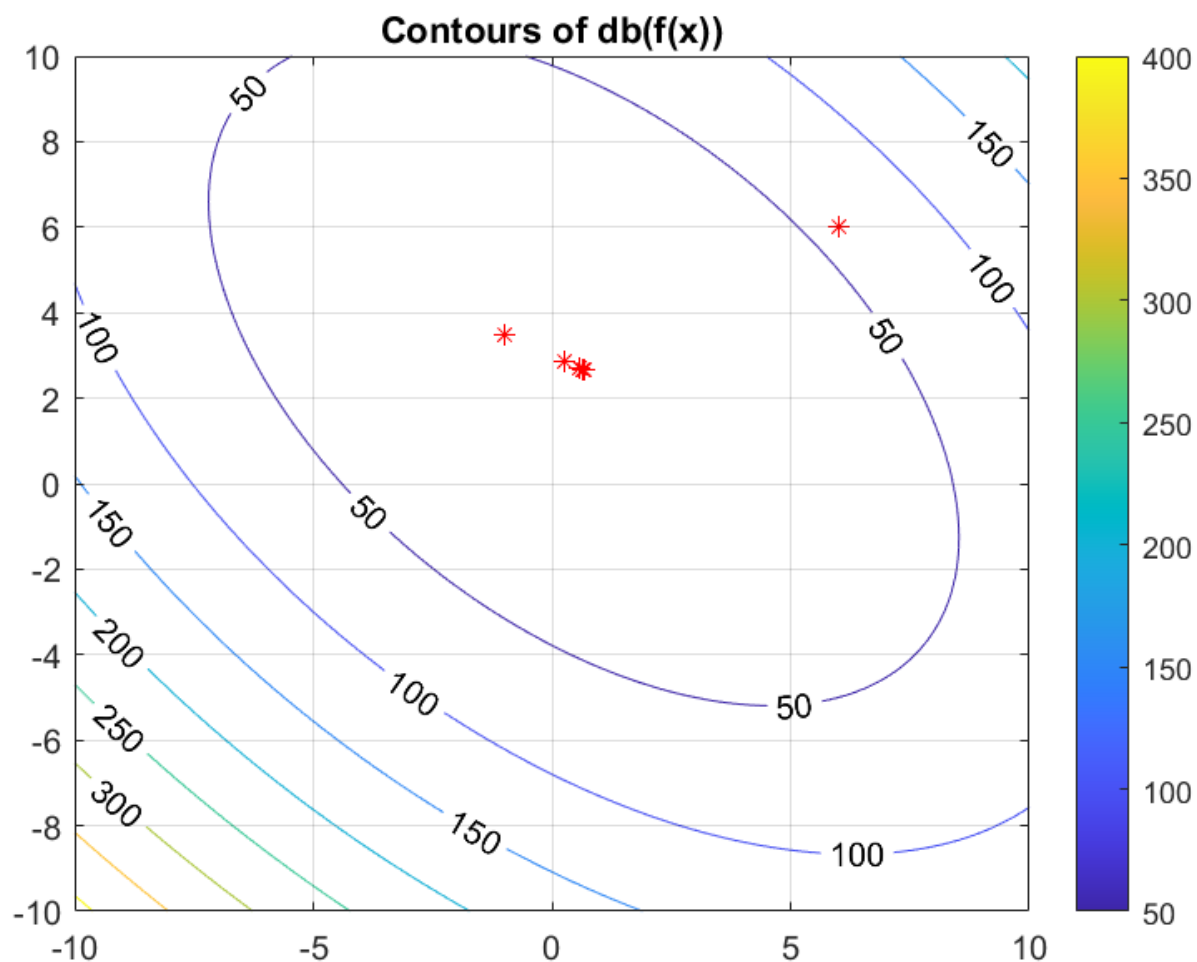
۷) از نقطه‌ی اولیه  $x_1 = x_2 = 6$  با رویکرد **alternation minimization** بین دو متغیر  $x_1$  و  $x_2$  مساله بهینه‌سازی را حل کنید. توجه کنید که در هر **alternation**، با مساله‌ی بهینه‌سازی جدیدی مواجه می‌شوید. چون مساله جدید ساده است، جواب فرم بسته برای آن در نظر بگیرید و دیگر احتیاجی نیست از **SD** یا الگوریتم‌های دیگر برای حل آن استفاده کنید. مسیر همگرایی را از مقدار اولیه تا مقدار بهینه در فضای دو بعدی  $x_1$  و  $x_2$  رسم کنید. **contour** ها را هم در تصویر به صورت همزمان نمایش دهید.





شکل 29

برای کانتورها داریم:




شکل 30


### سوال-8:

۸) قید  $x_1^2 + x_2^2 = 1$  یا به عبارت دیگر  $\|x\|_2 = 1$  را به مساله اضافه می کنیم. حال تابع هدف را با رویکرد Gradient Projection از نقطه ی اولیه  $x_1 = x_2 = 6$  و با استفاده از الگوریتم Steepest Descend و با  $\mu = 0.1$  حل کنید. مقدار بهینه به دست آمده را گزارش کنید.

برای حل مسئله ی مقید، باید از روش Gradient Projection استفاده کنیم:



شکل 31



شکل 32

نقطه‌ی همگرایی:

0.4943    0.8693

که خوب با قبلی متفاوت است چرا که باید قید مسئله رعایت شود که همان واحد بودن نرم نقطه‌ی پیدا شده است.

## سوال-9:

۹) با استفاده از روش ضرایب لاگرانژ، قسمت (۸) را به صورت ریاضی حل کنید و نشان دهید جواب به دست آمده در قسمت (۸) جواب مساله است.

$$\min_{x_1, x_2} f(x_1, x_2) = x_1^2 + x_2^2 - 4x_1 - 6x_2 + 13 + x_1x_2$$

$$\text{s.t.} \quad x_1^2 + x_2^2 = 1$$

$$L(x_1, x_2, \lambda) = x_1^2 + x_2^2 - 4x_1 - 6x_2 + 13 + x_1x_2 - \lambda(1 - x_1^2 - x_2^2)$$

$$\frac{\partial L}{\partial x_1} = 0 \Rightarrow 2x_1 - 4 + x_2 - \lambda(-2x_1) = 0 \quad \begin{cases} (2\lambda+2)x_1 + x_2 = 4 \\ x_1 + (2\lambda+2)x_2 = 6 \end{cases}$$

$$\frac{\partial L}{\partial x_2} = 0 \Rightarrow 2x_2 - 6 + x_1 - \lambda(-2x_2) = 0 \quad \begin{cases} x_1 + (2\lambda+2)x_2 = 6 \\ x_1^2 + x_2^2 = 1 \end{cases}$$

$$\frac{\partial L}{\partial \lambda} = 0 \Rightarrow 1 - x_1^2 - x_2^2 = 0 \Rightarrow x_1^2 + x_2^2 = 1$$

$$\Rightarrow x_2 = \sqrt{1-x_1^2} \Rightarrow \begin{cases} (2\lambda+2)x_1 + \sqrt{1-x_1^2} = 4 \\ x_1 + (2\lambda+2)\sqrt{1-x_1^2} = 6 \end{cases} \Rightarrow \lambda = 2.266$$

$$\Rightarrow x_2 = 0.869 \Rightarrow f^*(x_1, x_2) = 7.236$$

با تشکر

