

به نام خدا



Blind Source Separation (BSS)

تکلیف شماره

6

محمد رضا آرانی

810100511

دانشگاه تهران

1402/02/20

جدول محتویات

3	بخش اول:
3	قسمت-1:
9	قسمت-2:
11	قسمت-3:
19	قسمت-4:

بخش اول:

در این تمرین می خواهیم روش single channel sparse blind deconvolution را پیاده سازی کنیم. همان طور که در کلاس بحث شد این روش اساس multichannel sparse blind deconvolution را تشکیل می دهد.

دو داده ی تک کاناله نویزی x_1 و x_2 و یک داده ی دو کاناله ی X در ماتریس `hw7.mat` در اختیار شما قرار داده شده است.

قسمت-1:

الگوریتم مورد نظر برای این قسمت، پیاده سازی Sparse Blind Deconvolution در حوزه ی زمان است. مراحل این پیاده سازی و مدل کردن مسئله به صورت زیر است:

$$[\hat{s}, \hat{\mathbb{I}}] = \underset{t}{\operatorname{argmin}} \sum_t (x(t) - s(t) * \mathbb{I}(t))^2$$

$$S.t. \quad \mathbb{I}(t) = \sum_k (\alpha_k \delta(t - \tau_k))$$

$$\|s\|_2 = 1$$

$$|\tau_i - \tau_j| > L$$

$$\alpha_k > 0$$

برای حل این مسئله که در بالا نشان داده شده است، بازهم از Alternation Minimization استفاده می کنیم:

Step-1:

$\mathbb{Y}(t)$ is fixed \rightarrow obtain \hat{s} by $\hat{s} = \frac{\alpha^T Y}{\alpha^T \alpha}$; and then $\hat{s} = \frac{\hat{s}}{\|\hat{s}\|_2}$

Handwritten diagram illustrating the calculation of \hat{s} . It shows a $k \times L$ matrix Y and a $k \times 1$ vector α . The product $\alpha^T Y$ is calculated, resulting in a $1 \times L$ vector \hat{s} . The final result is $\hat{s} = \frac{\hat{s}}{\|\hat{s}\|_2}$.

شکل 1

Step-2:

\hat{s} is fixed \rightarrow obtain $\hat{\mathbb{W}}(t)$ by $\hat{b} = \frac{\hat{s}^T Z}{\hat{s}^T \hat{s}}$

Handwritten diagram illustrating the calculation of \hat{b} . It shows a $L \times (T-L+1)$ matrix Z and a $L \times 1$ vector \hat{s} . The product $\hat{s}^T Z$ is calculated, resulting in a $1 \times (T-L+1)$ vector \hat{b} . The final result is $\hat{b} = \frac{\hat{s}^T Z}{\hat{s}^T \hat{s}}$.

شکل 2

در واقع ماتریس Y از کنار هم قرار دادن K تا ستون که هر یک L تا نمونه از قسمت‌های
محتمل وقوع سیگنال در ماتریس مشاهدات هستند می‌باشد.

همچنین ماتریس Z نیز از کنارهم قراردادن نمونه‌های با طول L به صورت شیفت یافته از روی سیگنال مشاهدات است. به این ترتیب یک ماتریس با تعداد ردیف‌های L و تعداد ستون‌های $T-L$ داریم.


پیاده‌سازی این روش در متلب به صورت زیر است:

```
disp(char(hex2dec('0428'))+"(t) is fixed & then S is Fixed");
W(t) is fixed & then S is Fixed
IterMax=50;
rng(1);
Alpha_vec = randn(K,1);
Z = buffer(y1 ,L, L-1 , 'nodelay');
T = length(y1);
y_hat = zeros(size(y1));
for i=1:IterMax
    % Step-1: Shai is fixed
    S_hat_time = Signal_Selected_k*pinv(Alpha_vec');
    % Normalize S hat
    S_hat_time = S_hat_time/norm(S_hat_time);
    % Step-2: S is fixed
    Chosen_Index_Z = zeros(1,K);
    temp_Z = Z;
    b = zeros(1,T);
    for k=1:K
        [~,index_max] = max( abs( S_hat_time'*temp_Z ));
        Chosen_Index_Z(1,k) = index_max;
        if(index_max-L/4+1<0)
            Index_to_Change = [1:L];
        else
            Index_to_Change = [index_max-L/4+1:index_max+3*L/4];
        end
        b(1,index_max) = S_hat_time'*temp_Z(:,index_max)/( S_hat_time'*S_hat_time );
        Alpha_vec(k,1) = b(1,index_max);
        Signal_Selected_k(:,k) = y1(Index_to_Change) ;%Chosen_Index_Z(1,k)-
        L/4+1:Chosen_Index_Z(1,k)+3*L/4
        y_hat(1,Index_to_Change) = Signal_Selected_k(:,k);
        temp_Z(:, Index_to_Change ) = 0;
    end
end

figure()
plot(y_hat);
grid on
```

```
hold on
plot(y1,'r--');
title("x^ vs x")
xlabel(" Samples")
legend("x hat" , "x");
hold off
```

در واقع برای انتخاب مکان‌های اولیه، ابتدا سیگنال را smooth کرده و سپس پیک‌های آن را انتخاب کردیم و در نتیجه مکان‌های نسبی اولیه انتخاب به دست آمدند:



شکل 3

```
windowSize = 31;
polyOrder = 2;
y1 = sgolayfilt(x1, polyOrder, windowSize);
figure()
plot(y1)
[Peaks_y1 , Locs_y1] = findpeaks(y1);

Good_Indices_Peaks = find( ((Peaks_y1)>mean(abs(y1))) );
plot(Locs_y1(Good_Indices_Peaks),Peaks_y1(Good_Indices_Peaks),'r*');

% Loc_target_k = zeros(1,K);
Loc_target_k = Locs_y1(Good_Indices_Peaks);
Selected_Indices = zeros(2,K) ;
```

```

Signal_Selected_k = zeros(L,K);


for k=1:K
    Signal_Selected_k(:,k) = x1(Loc_target_k(1,k)-L/4+1:Loc_target_k(1,k)+3*L/4);
    Selected_Indices(:,k) = [ Loc_target_k(1,k)-L/4+1 ; Loc_target_k(1,k)+3*L/4 ];
    plot(Selected_Indices(1,k)*ones(1,10),linspace(-2*abs(min(y1)),2*max(abs(y1)),10)
    , 'black--' );
    plot(Selected_Indices(2,k)*ones(1,10),linspace(-2*abs(min(y1)),2*max(abs(y1)),10)
    , 'black--' );

end
grid on
title("Selected "+K+" Signals");
xlabel("Samples")
ylabel("Amplitude")
hold off

```



در بالا برای smooth کردن یک سیگنال، از بین روش‌های موجود بسیار، روش فیلتر کردن توسط فیلتر **savitzky-Golai** را انتخاب کردیم چرا که نتایج بهتری میداد و پارامترهای قابل تنظیم آن دم دست تر بودند. انتخاب‌های دیگر مانند انتخاب فیلتر Lowpass و یا استفاده از Moving Average فیلتر نیز مطرح بودند.

پس از همگرایی در 50 تکرار به خروجی زیر می‌رسیم:



شکل 4

مشاهده می‌شود به خوبی سیگنال بازیابی و بازسازی شده است و مسئله‌ی Blind Deconvolution در حوزه‌ی زمان برای یک تک کانال حل شده است.



شکل 5

قسمت-2:

با استفاده از همین روش، برای داده‌ی سیگنال x_2 نیز داریم:

```
x2 = Data_hw7.x2;

windowSize = 35;
polyOrder = 2;
y2 = sgolayfilt(x2, polyOrder, windowSize);

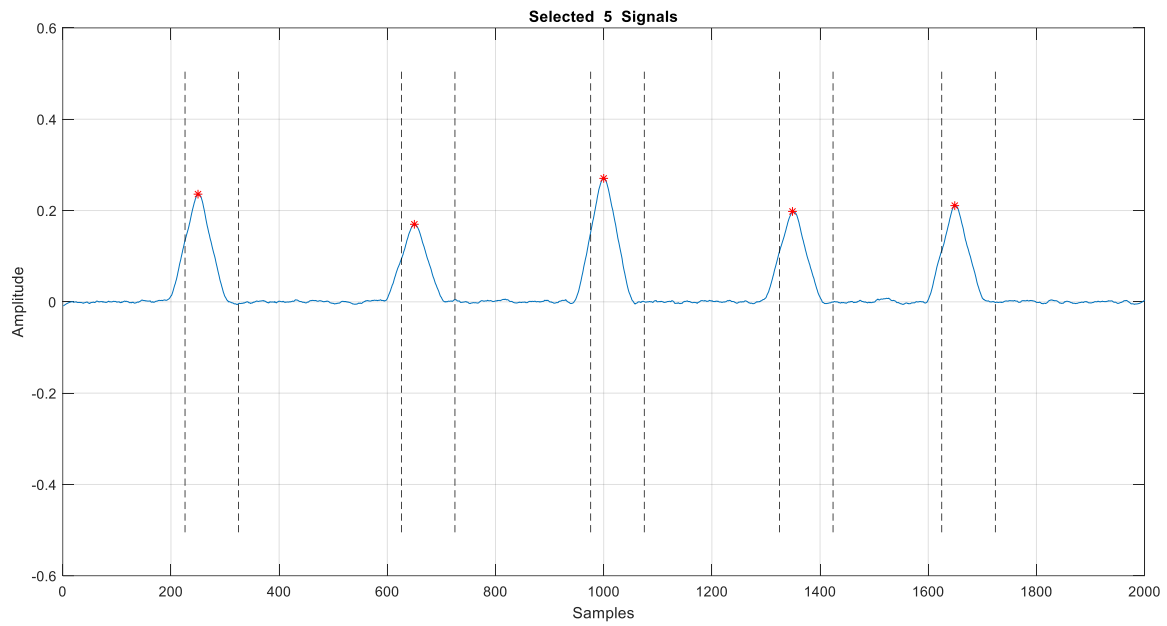
figure()
plot(y2)
[Peaks_y2 , Locs_y2] = findpeaks(y2);

Good_Indices_Peaks = find( ((Peaks_y2)>mean(abs(y2))) );
hold on
plot(Locs_y2(Good_Indices_Peaks),Peaks_y2(Good_Indices_Peaks),'r*');

% Loc_target_k = zeros(1,K);
Loc_target_k = Locs_y2(Good_Indices_Peaks);
Selected_Indices = zeros(2,K) ;
Signal_Selected_k = zeros(L,K);


for k=1:K
    Signal_Selected_k(:,k) = x2(Loc_target_k(1,k)-L/4+1:Loc_target_k(1,k)+3*L/4);
    Selected_Indices(:,k) = [ Loc_target_k(1,k)-L/4+1 ; Loc_target_k(1,k)+3*L/4 ];
    plot(Selected_Indices(1,k)*ones(1,10),linspace(-2*abs(min(y1)),2*max(abs(y1)),10)
    , 'black--' );
    plot(Selected_Indices(2,k)*ones(1,10),linspace(-2*abs(min(y1)),2*max(abs(y1)),10)
    , 'black--' );

end
grid on
title("Selected "+K+" Signals");
xlabel("Samples")
ylabel("Amplitude")
hold off
```




شکل 6

برای داده‌ی x_2 هم به همین ترتیب داریم:



شکل 7

مشاهده می‌شود به خوبی سیگنال بازیابی و بازسازی شده است و مسئله‌ی Blind Deconvolution در حوزه‌ی زمان برای یک تک کانال حل شده است.




شکل 8

قسمت-3:

۳- ابتدا داده‌ی دو کاناله‌ی X را رسم کرده و به صورت چشمی آن را بررسی کنید. روش multichannel sparse blind deconvolution را روی آن اعمال کرده و دو شکل موج اسپایکی و دو سری زمانی که این داده را به وجود آورده اند به دست آورید. طول شکل موج ها را برابر $L = 100$ سمپل و تعداد رخداد ها را برای هر کدام برابر $K = 5$ در نظر بگیرید.

نکته‌ی مهم در این قسمت، تخمین درست ماتریس میکس برای مانال‌ها در کنار انجام درست *Single Channel Blind Deconvolution* است.

بررسی چشمی داده‌های این سیگنال به صورت زیر انجام شده است:



شکل 9

در کانال اول، از بین این 8 عدد پیک شناخته شده، 5 تای آنها باید انتخاب شود. این فرآیند در تابع متناسب با *single channel blind deconvolution* اتفاق می افتد. این تابع به صورت زیر است:

```
function [ y_hat , b, S_hat_time ] = Single_Ch_Time_Dec(x,IterMax,K,L)

T = length(x);
% Smooth the Input:
windowSize = 35;
polyOrder = 2;
y = sgolayfilt(x, polyOrder, windowSize);

% figure()
% plot(y)
[Peaks_y , Locs_y] = findpeaks(y);

Good_Indices_Peaks = find( ((Peaks_y)>mean(abs(y))) );
% hold on
% plot(Locs_y(Good_Indices_Peaks),Peaks_y(Good_Indices_Peaks),'r*');
```

```

% Loc_target_k = zeros(1,K);
Loc_target_k = Locs_y(Good_Indices_Peaks);
Signal_Selected_k = zeros(L,K);
cntr = 1;
Indexes_to_remove = [];

for i=2:length(Loc_target_k)
    if(Loc_target_k(1,i) - Loc_target_k(1,i-1)<L)
        Indexes_to_remove(cntr) = i;
        cntr = cntr+1;
    end
end
Loc_target_k(Indexes_to_remove) = [];
Indexes_to_remove = [];
% CHoose Randomly K of found occurences:
if (length(Loc_target_k)>K)
    Indexes_to_remove = randperm(length(Loc_target_k),length(Loc_target_k)-K);
    Loc_target_k(Indexes_to_remove) = [];
else

    if(Loc_target_k(1,end)+1.5*L < T )
        Loc_target_k(1,end+1) = Loc_target_k(1,end)+1.5*L ;
    elseif( Loc_target_k(1,end)-1.5*L - Loc_target_k(1,end-1) > L )
        Loc_target_k(1,end+1) = Loc_target_k(1,end)-1.5*L;
    elseif (Loc_target_k(1,1)>2*L)
        Loc_target_k(1,end+1) = Loc_target_k(1,1)-L;
    end
    Loc_target_k = sort(Loc_target_k);
    num_to_add = K - length(Loc_target_k);

    if(num_to_add>0)
        for i=1:num_to_add
            diff_vector = diff(Loc_target_k) ;
            Possible_Candidate_to_Insert_Next_To = find(diff_vector>L);
            Loc_target_k(1,end+1) =
Loc_target_k(Possible_Candidate_to_Insert_Next_To(1,end))-L;
            Loc_target_k = sort(Loc_target_k);
        end
    end
end

for k=1:K
    Signal_Selected_k(:,k) = x(Loc_target_k(1,k)-L/4+1:Loc_target_k(1,k)+3*L/4);
end

```

```

% IterMax=10;
Alpha_vec = randn(K,1);
Z = buffer(y ,L, L-1 , 'nodelay');
T = length(y);
y_hat= zeros(size(y));

for i=1:IterMax
    % Step-1: Shai is fixed
    S_hat_time = Signal_Selected_k*pinv(Alpha_vec');
    % Normalize S hat
    S_hat_time = S_hat_time/norm(S_hat_time);
    % Step-2: S is fixed
    Chosen_Index_Z = zeros(1,K);
    temp_Z = Z;
    b = zeros(1,T);
    for k=1:K
        [~,index_max] = max( abs( S_hat_time'*temp_Z ));
        Chosen_Index_Z(1,k) = index_max;
        if(index_max-L/4+1<0)
            Index_to_Change = 1:L;
        else
            Index_to_Change = index_max-L/4+1:index_max+3*L/4;
        end
        b(1,index_max) = S_hat_time'*temp_Z(:,index_max)/( S_hat_time'*S_hat_time );
        Alpha_vec(k,1) = b(1,index_max);
        Signal_Selected_k(:,k) = y(Index_to_Change) ;%Chosen_Index_Z(1,k)-
        L/4+1:Chosen_Index_Z(1,k)+3*L/4
        y_hat(1,Index_to_Change) = Signal_Selected_k(:,k);
        temp_Z(:, Index_to_Change ) = 0;
    end
end

end

```

همچنین فرض شده است که اگر از K تا نقطه کمتر در پردازش اولیه پیدا شد، به تعداد کمبودها نقطه‌ی جدید پیدا شود. نقاط جدید پیدا شده دارای قید حداقل فاصله با عناصر مجاور خود می‌باشند.

همچنین قدم‌های برداشته شده برای رسیدن به خروجی مناسب به صورت زیر است:

```
IterMax = 2;
X = Data_hw7.X;
[Row_X , Col_x] = size(X);
K = 5;
L=100;
% Generate Random A Matrix:

A = randn(Row_X);
A = normalize(A, 'norm', 2) ; % Normalize Columns of A

IterMax_2 = 50;
Rep_Error = zeros(1,IterMax_2);
best_Rep_Err = inf;
for i=1:IterMax_2

    S_hat = A\X;

    y_hat_Xj = zeros(Row_X,T) ;
    b_Xj      = zeros(Row_X,T) ;
    S_hat_time_Xj = zeros(Row_X,L);

    for j=1:Row_X
        flip = 0;
        if ( abs(min(S_hat(j,:)))>abs(max(S_hat(j,:))) )
            S_hat(j,:) = -S_hat(j,:);
            flip = 1;
        end
        [ y_hat_Xj(j,:) , b_Xj(j,:) , S_hat_time_Xj(j,:) ] =
Single_Ch_Time_Dec(S_hat(j,:),IterMax,K,L);
        if(flip)
```

```

        y_hat_Xj(j,:) = -y_hat_Xj(j,:) ;
        b_Xj(j,:) = -b_Xj(j,:) ;
        S_hat_time_Xj(j,:) = -S_hat_time_Xj(j,:) ;
    end
    % S_hat(j,:) = conv( b_Xj(j,:) , S_hat_time_Xj,"same" ) ;
end
% S_hat = [conv(Si1,S1_hat,'same');conv(Si2,S2_hat,'same')];
S_hat = y_hat_Xj;

% Step-2: S is fixed --> Find A:
A = X*pinv(S_hat);
A = normalize(A, 'norm', 2) ;

% Calculate the Representation Error:
Rep_Error(1,i) = norm( X-A*S_hat , "fro" );
if (abs(Rep_Error(1,i) - mean(Rep_Error(1,1:i))) < 1e-3 ) && (i>5) % Convergence
Happens
    break;
elseif( Rep_Error(1,i)< best_Rep_Err )
    best_Rep_Err = Rep_Error(1,i);
    Best_Index_Rep_Err = i;
    Best_S_hat = S_hat;
    Best_b_vec = b_Xj ;
    Best_S_hat_k = S_hat_time_Xj;
end
end
end


```

در ابتدا باید ماتریس رندوم A را تولید و سپس نرمالایز کنیم. در ادامه باید ماتریس S را به دست آورده که هر سطر این ماتریس را برای یکبار *Single Channel Deconvolution* انجام می‌دهیم.

پس از این قسمت، باید به سراغ *update* کردن A برویم، برای اینکار، از رابطه‌ی $A = X * pinv(S)$ استفاده می‌کنیم.

- توجه شود قبل از استفاده از تابع *Single channel blind deconv.* ابتدا یک پیش پردازش صورت می‌گیرد تا سعی شود *spike* ها به سمت مثبت باشند و سپس برای این سیگنال پردازش انجام شود.

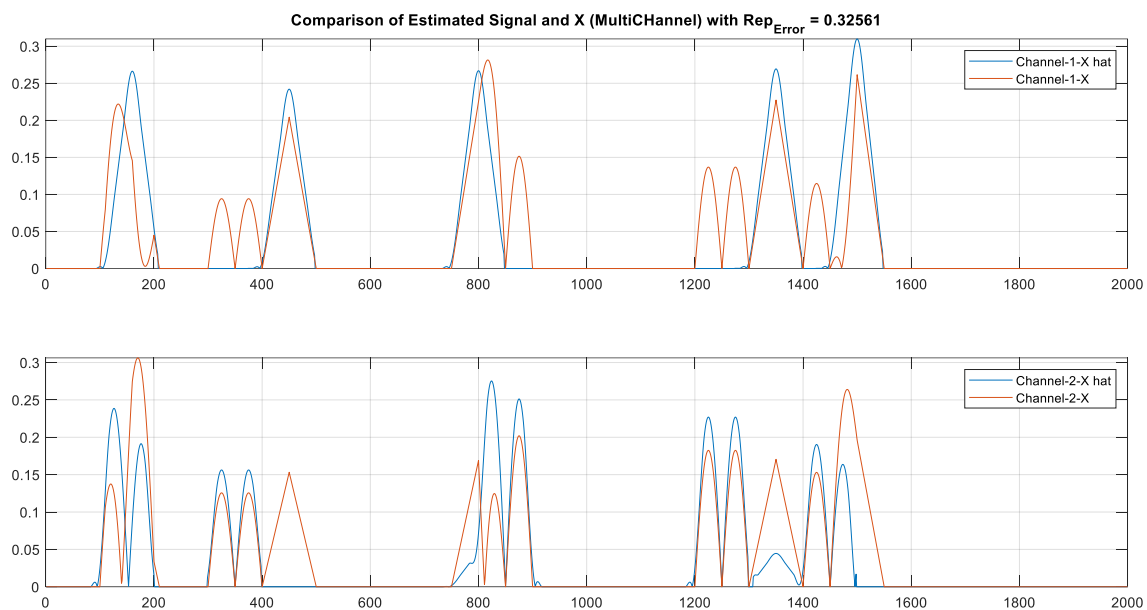
- در هر تکرار، بهترین‌ها تا آن تکرار را نگه داشته و ذخیره می‌کنیم. در نهایت پس از همگرایی، نمودار خطا متناسب با تعداد تکرار را رسم کرده ایم:



شکل 10

نمودار خطای نمایش بر حسب تعداد تکرار

تقریباً خطای نمایش به مقدار 0.3 رسیده است که بسیار مناسب است:



شکل 11

با کمی دقت متوجه می‌شویم که ماتریس A تقریباً به درستی تخمین زده شده است ولی همچنان قسمت‌های کمی از کانال 1 در کانال 2 دیده می‌شوند و بالعکس.

قسمت-4:

۴- قسمت ۱ را مجدداً در نظر بگیرید. فرض کنید داده ی x_1 را به حوزه ی فرکانس می بریم. با پردازشی در حوزه ی فرکانس، مساله ی قسمت ۱ را حل کنید.

برای این قسمت ابتدا باید فرمول بندی مسئله انجام شود:

in Time we had:

$$[\hat{s}, \hat{\mathbb{I}}] = \operatorname{argmin} \sum_t (x(t) - s(t) * \mathbb{I}(t))^2$$

in Frequency we have:

$$\hat{x}(f) = \hat{s}(f) \cdot \hat{\mathbb{I}}(f)$$

Where $\hat{\mathbb{I}}(f) = \sum_{k=1 \text{ to } K} (\alpha_k e^{-j2\pi f \tau_k})$

برای ادامه ابتدا متناسب با طیف موجود، قسمتی که سیگنال اصلی در آن طیف فرکانسی نیست را از s و \mathbb{I} در حوزه ی فرکانس حذف می کنیم.

از این قسمت به بعد دوباره رویکرد ما استفاده از *Alternation Minimization* است:

به ترتیب که ابتدا بردار $\hat{\mathbb{I}}(f)$ را ثابت گرفته و سپس $\hat{s}(f)$ را به دست می آوریم. نکته ی مهم آن است که در حوزه ی فرکانس باید سیگنال $\hat{s}(f)$ را متقارن در نظر بگیریم چرا که باید یک سیگنال زمانی حقیقی در حوزه ی زمان به ما بدهد.

پس به این صورت به دست خواهد آمد:

$$\hat{s}(f) = \frac{1}{2} \left(\frac{(\hat{x}(f))}{\hat{\mathbf{M}}(f)} + \frac{(\hat{x}(-f))^*}{\hat{\mathbf{M}}(-f)^*} \right)$$

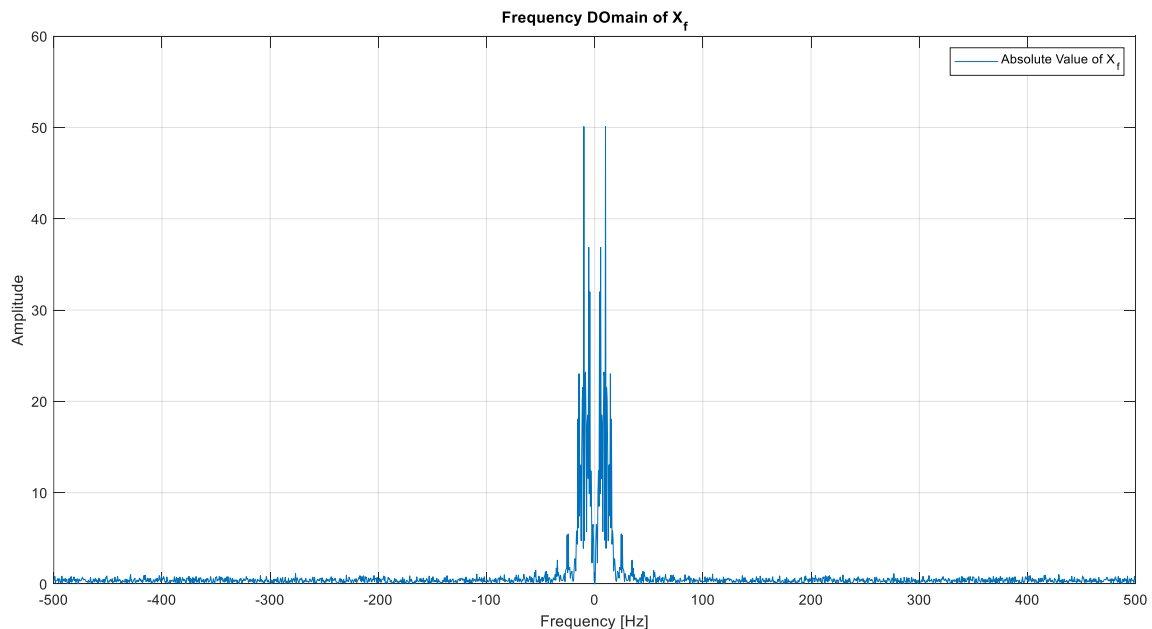
با این فرم، قدم اول الگوریتم به پایان می‌رسد. در قدم بعدی باید با دانسته فرض کردن $\hat{s}(f)$ به سراغ تعیین $\mathcal{M}(f)$ برویم.

برای قدم بعدی از تکنیک *ifft* با تعداد سمپل برابر T استفاده می‌کنیم. در واقع داریم:

$$\hat{y}(f) = \frac{\hat{x}(f)}{\hat{s}(f)} = \sum_k (\alpha_k e^{-j2\pi f \tau_k})$$

به این ترتیب با گرفتن یک *ifft* از $\hat{y}(f)$ می‌توان مکان و اندازه‌ی سیگنال را به دست آورد که به ترتیب همان τ_k ها و α_k های ما هستند.

با توجه به مراحل بالا داریم:



شکل 12

در حوزه‌ی فرکانس به نظر می‌رسد از 100 هرتز به بعد فرکانس نداریم. پس آنها را برابر 0 هم در \hat{S} و هم در $\hat{\mathbb{M}}(f)$ می‌گیریم.

```
Indices_TO_Remove = find(abs(freq)>100) ;
Y_F = X_f;
Y_F(Indices_TO_Remove) = 0;
T = length(Y_F);
Y_F = fftshift(Y_F)/norm(abs(Y_F));
% Random Generation of SHAI:
SHAI_f_hat = randn(size(Y_F))+1j*randn(size(Y_F)) ;
close all;
figure()
Rep_Error = zeros(1,IterMax);
Mean_Error =inf;
IterMax=150;
for i=1:IterMax
    % Step-1: S_f Update based on fixed SHAI_hat

    S_f_hat = 0.5*( (Y_F)./(SHAI_f_hat) + conj( flip(Y_F) )./conj( flip(SHAI_f_hat) ) );
    % Step-2: Obtain "SHAI hat"
    YY_F_hat =zeros(size(Y_F));
    NonZero_Indexes = find(S_f_hat ~= 0);
    YY_F_hat(NonZero_Indexes) = Y_F(NonZero_Indexes)./S_f_hat(NonZero_Indexes);
    SHAI_hat = ifft((YY_F_hat),T);

    % Choose with deflation:
    TAU_vec = zeros(1,K);
    Temp_SHAI_HAT = SHAI_hat;

    for tau_ind=1:K
        [~,cache_Tau] = sort(abs(Temp_SHAI_HAT));
        TAU_vec(1,tau_ind) = cache_Tau(1,end);
        if(cache_Tau(1,end)-L/2<1)
            Temp_SHAI_HAT(1,1:L) = 0;
        elseif(cache_Tau(1,end)+L/2>length(Temp_SHAI_HAT))
            Temp_SHAI_HAT(1,end:end-L) = 0;
        else
            Temp_SHAI_HAT(1,cache_Tau(1,end)-L/2:cache_Tau(1,end)+L/2) = 0;
        end
    end
end
% [ ~ , TAU_vec ] = sort(abs(SHAI_hat));
% TAU_vec = sort(TAU_vec(1,1:K));
```


```

Alpha_Vec = SHAI_hat(TAU_vec);
Alpha_Vec = Alpha_Vec/norm(Alpha_Vec);

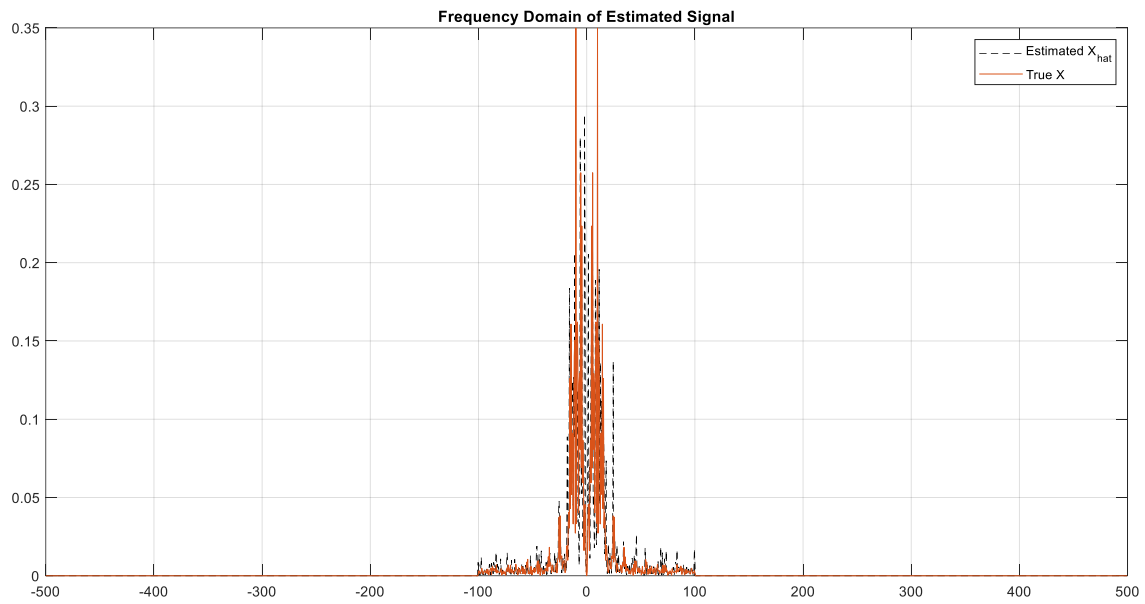
SHAI_time = zeros(1,T);
SHAI_time(TAU_vec) = abs(real(Alpha_Vec));

SHAI_f_hat = (fft(SHAI_time));
SHAI_f_hat = SHAI_f_hat/norm(abs(SHAI_f_hat),"fro"); % Normalize
S_hat_Time = real(ifft((S_f_hat)));
X_hat_F = SHAI_f_hat.*S_f_hat;
X_hat_F = X_hat_F/norm(abs(X_hat_F) , "fro" ); % Normalize
X_hat_Time = conv(S_hat_Time,SHAI_time , "same");
X_hat_Time = X_hat_Time/norm(X_hat_Time,"fro"); % Normalize
% Error Calculation:
Rep_Error(1,i) = norm( ifft(Y_F)/max(ifft(Y_F)) -
ifft(SHAI_f_hat.*S_f_hat)/max(ifft(SHAI_f_hat.*S_f_hat)) , "fro" );
if(Mean_Error >Rep_Error(1,i) )
    Mean_Error = Rep_Error(1,i);
    Best_Indice = i;
    Best_S_hat_Time = S_hat_Time;
    Best_SHAI_f_hat = SHAI_f_hat;
    Best_SHAI_time = SHAI_time;
    Best_TAU_vec = TAU_vec;
    Best_Alpha_Vec = Alpha_Vec;
    Best_X_hat_F = X_hat_F;
end
%close all;
drawnow
subplot(2,1,1)
plot(x1,'r--');
hold on
plot(X_hat_Time);
stem(SHAI_time);
hold off;
subplot(2,1,2)
plot(real(ifft(X_hat_F)));
end


```



شكل 13

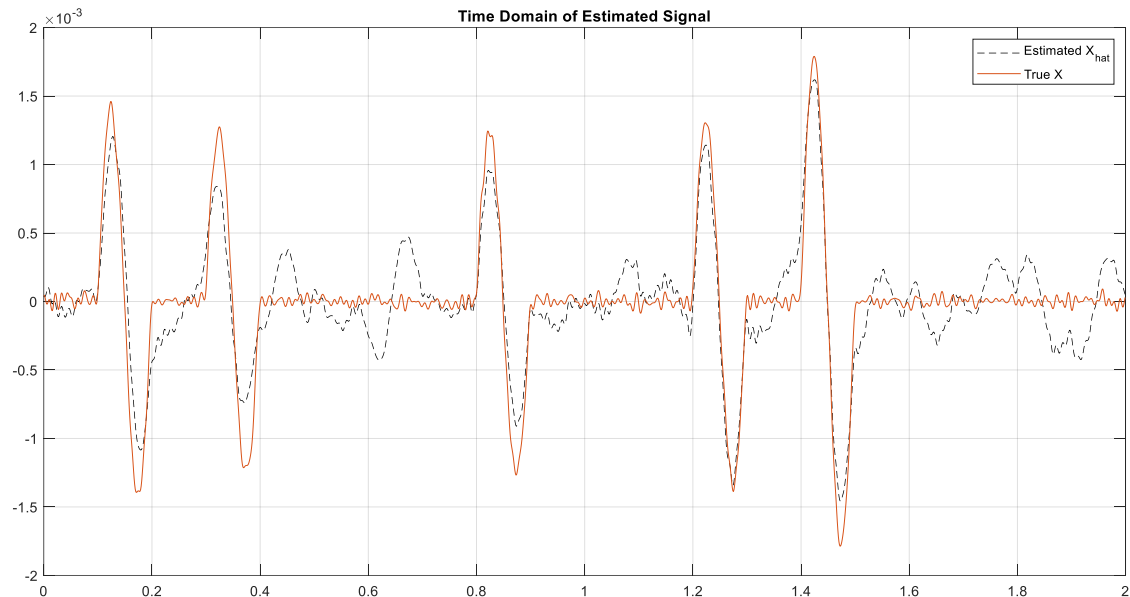


شكل 14



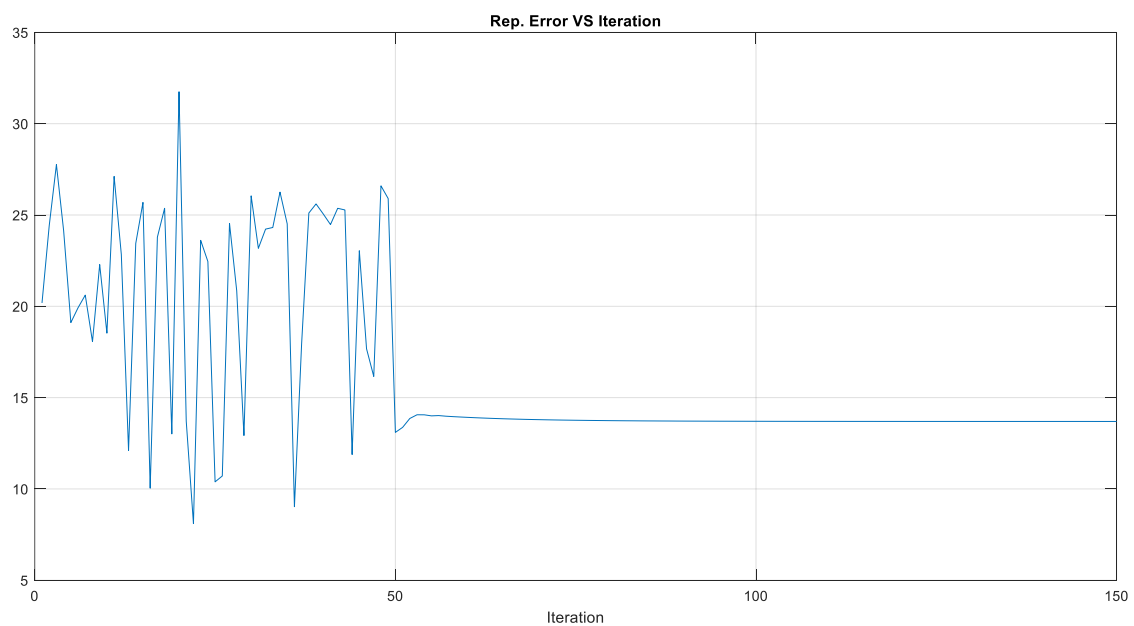
شكل 15

بهترین نتیجه برای تمامی تکرار ها به صورت زیر است:



شکل 16

به خوبی همگرا شده است!



شکل 17

همگرایی نیز در شکل نمودار خطا بر حسب تعداد iteration نیز مشهود است!

پایان